意味で検索することで表記揺れは解決できるのでしょうか？

堀本 泰弘

株式会社クリアコード

PostgreSQL Conference Japan 2026

2026-11-27





目次

1. 表記揺れの問題
2. 解決方法と対策
3. 検証

表記揺れの問題

検索語の表記が文書の表記と違うと、ヒットしないことがある



サーバー	↔	サーバ	長音の有無
斉藤	↔	齋藤	異体字
11月	↔	１１月	半角・全角

同じ意味でも表現は異なる。単純な文字列一致では対応できないことがある。



表記揺れの問題

- ユーザーが知りたいことと、文書に書かれている表現は必ずしも一致しない
- 自然言語なので、同じ意味でも表現が異なることはよくある

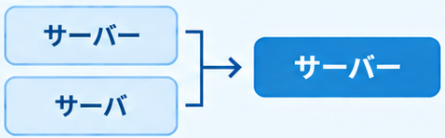
解決方法と対策

解決方法

1 正規化

表記の揺れを統一することで、
同じ意味の語を同一として扱う。

例



メリット

- 表記の揺れを統一できる
- 規則が明確で処理が再現可能

デメリット

- 未知の表記は対応しにくい

2 辞書

あらかじめ用意した辞書に基づき、
同義語・類義語をまとめて検索する。

例

辞書の例

斉藤	↔	齋藤
スマホ	↔	スマートフォン
EV	↔	電気自動車

メリット

- 同義語・類義語を確実にカバーできる
- 特定の業界・分野に強い

デメリット

- 辞書の整備・メンテナンスが必要

3 意味での検索

検索語と文書をベクトルに変換し、
意味的な近さで検索する。

例



メリット

- 言い換えや関連語を柔軟に見つけられる
- 文脈に応じた意味の近さで検索できる

デメリット

- ベクトルの近さは「ユーザー意図」と同義ではない



解決方法と対策

- 従来は正規化と辞書を用いて解決
- 近年は意味で検索する方法も表現が異なる文書を発見する手段に
- しかし、意味での検索は正規化や辞書の単純な上位互換ではない



検証

- 「正規化・辞書による検索」と「意味検索」結果にどのような違いがあるのか？



検証

実際にテストデータを使って検証

- 各々の方式の特徴、得手不得手
- どのようなケースで効果が見込めるのか

検証：検証対象

今回の検証対象

検証範囲

01 表記揺れ

同じ言葉・対象でも、
文字の形や形式が異なる

長音
サーバー ／ サーバ

異体字
斉藤 ／ 齋藤

全角・半角
11月 ／ １１月

文字列の表記差

02 同義語・類義語

異なる言葉が
同じ・近い意味を表す

名称の違い
スマートフォン ／ スマホ

言い換え
修理する ／ 直す

語彙・意味の対応

03 同音異義語

読みが同じでも、
意味は異なる

同じ読み
はし

意味の候補
橋 ／ 箸 ／ 端

意味の識別



検証：検証項目

1. 表記や表現が異なっても、意図した文書を検索できるか
2. 意味の近い別の文書を誤って返さないか
3. 正規化・辞書による方法と意味による検索で、得意・不得意に違いがあるか
4. PGroongaとpgvectorで、同じモデルを使っても順位や検索結果が変わるか

検証：検索方式

比較する4つの検索方式

同じ検索語・文書集合を使い、方式ごとの違いを確認する

共通の入力
検索語 ＋ 文書集合

1 PostgreSQL 標準 キーワード検索

キーワード検索の流れ

文字列を正規化
↓
キーワードで照合

検索の特徴
正規化した文字列の
一致を調べる

文字列の一致を重視

2 PGroonga キーワード検索

キーワード検索の流れ

Normalizer・辞書
↓
ルールに沿って照合

検索の特徴
明示したルールを使って
検索する

辞書・ルールを重視

3 PGroonga セマンティックサーチ

意味検索の流れ

モデルで意味表現
↓
意味的な近さで検索

検索の特徴
言語モデルによる
意味表現を利用する

意味的な近さを利用

4 pgvector セマンティックサーチ

意味検索の流れ

モデルで意味表現
↓
意味的な近さで検索

検索の特徴
言語モデルによる
意味表現を利用する

意味的な近さを利用



検証：比較条件

PGroongaとpgvectorの比較では
次の条件をそろえる

- 同一の検索語と文書集合
- 同一の埋め込みモデル



検証：結果

当日発表予定



検証：検証の再現

- 検証に使用した環境・データ・スクリプト
  - https://github.com/komainu8/rabbit-slide-komainu8-postgresql-conference-japan-2026