意味で検索することで表記揺れは解決できるのでしょうか？

堀本 泰弘

株式会社クリアコード

PostgreSQL Conference Japan 2026

2026-11-27





目次

1. 表記揺れの問題
2. 解決方法と対策
3. 検証

表記揺れの問題

検索語の表記が文書の表記と違うと、ヒットしないことがある



サーバー	↔	サーバ	長音の有無
斉藤	↔	齋藤	異体字
11月	↔	１１月	半角・全角

同じ意味でも表現は異なる。単純な文字列一致では対応できないことがある。



表記揺れの問題

- ユーザーが知りたいことと、文書に書かれている表現は必ずしも一致しない
- 自然言語なので、同じ意味でも表現が異なることはよくある

解決方法と対策

解決方法

1 正規化

表記の揺れを統一することで、
同じ意味の語を同一として扱う。

例

サーバー
サーバ
→ サーバー

メリット
- 表記の揺れを統一できる
- 規則が明確で処理が再現可能

デメリット
- 未知の表記は対応しにくい

2 辞書

あらかじめ用意した辞書に基づき、
同義語・類義語をまとめて検索する。

例

辞書の例

斉藤	↔	齋藤
スマホ	↔	スマートフォン
EV	↔	電気自動車

メリット
- 同義語・類義語を確実にカバーできる
- 特定の業界・分野に強い

デメリット
- 辞書の整備・メンテナンスが必要

3 意味での検索

検索語と文書をベクトルに変換し、
意味的な近さで検索する。

例



メリット
- 言い換えや関連語を柔軟に見つけられる
- 文脈に応じた意味の近さで検索できる

デメリット
- ベクトルの近さは「ユーザー意図」と同義ではない



解決方法と対策

- 従来は正規化と辞書を用いて解決
- 近年は意味で検索する方法も表現が異なる文書を発見する手段に
- しかし、意味での検索は正規化や辞書の単純な上位互換ではない



検証

- 「正規化・辞書による検索」と「意味検索」結果にどのような違いがあるのか？



検証

実際にテストデータを使って検証

- 各々の方式の特徴、得手不得手
- どのようなケースで効果が見込めるのか

検証：検証対象

今回の検証対象

検証範囲

01 表記揺れ

同じ言葉・対象でも、
文字の形や形式が異なる

長音
サーバー／サーバ

異体字
斉藤／齋藤

全角・半角
11月／１１月

文字列の表記差

02 同義語・類義語

異なる言葉が、
同じ・近い意味を表す

名称の違い
スマートフォン／スマホ

言い換え
修理する／直す

類似表現
目的に合う別の言い方

語彙・意味の対応

03 同音異義語

読みが同じでも、
意味は異なる

同じ読み
はし

意味の候補
橋／箸／端

確認すること
文脈から意図を判断できるか

意味の識別



検証：検証項目

1. 表記や表現が異なっても、意図した文書を検索できるか
2. 意味の近い別の文書を誤って返さない
3. 正規化・辞書による方法と意味による検索で、得意・不得意に違いがあるか
4. PGroongaとpgvectorで、同じモデルを使っても順位や検索結果が変わるか

検証：検索方式

比較する4つの検索方式

検索方式

同じ検索語・文書集合を使い、方式ごとの違いを確認する

共通の入力
検索語 ＋ 文書集合

1 PostgreSQL標準

キーワード検索

文字列を正規化

↓

キーワードで照合

正規化した文字列の一致を調べる

2 PGroonga

キーワード検索

Normalizer・辞書

↓

ルールに沿って照合

明示したルールを使って検索

3 PGroonga

セマンティックサーチ

モデルで意味表現

↓

意味的な近さで検索

言語モデルによる意味表現を利用

4 pgvector

セマンティックサーチ

モデルで意味表現

↓

意味的な近さで検索

言語モデルによる意味表現を利用



検証：比較条件

PGroongaとpgvectorの比較では
次の条件をそろえる

- 同一の検索語と文書集合
- 同一の埋め込みモデル



検証：結果

当日発表予定



検証：検証の再現

- 検証に使用した環境・データ・スクリプト
  - https://github.com/komainu8/rabbit-slide-komainu8-postgresql-conference-japan-2026